Bazele PyTorch

Bibliografie:

- 1. Deep Learning with PyTorch, Eli Stevens, Luca Antiga, Thomas Viehmann, Manning; 1st edition (August 4, 2020)
- 2. PyTorch Pocket Reference: Building and Deploying Deep Learning Models, by Joe Papa, O'Reilly Media; 1st edition (June 1, 2021)

Pytorch este un framework open source folosit pentru deep learning. Este disponibil la https://pytorch.org/. Poate folosi placa grafica (NVIDIA, AMD), procesor, Tensor Processing Units (TPUs). Se poate face antrenare distribuita (de exemplu, folosind placi grafice instalate pe mai multe calculatoare legate in retea).

Instalare

Instalarea se face conform instructiunilor de la https://pytorch.org/get-started/locally/, de exemplu:

```
conda install pytorch torchvision torchaudio cpuonly -c pytorch
sau

pip install torch torchvision torchaudio
sau

pip install torch torchvision torchaudio --index-url
```

primele doua fiind cu instalare doar pentru PU, iar ultima foloseste CUDA, daca placa grafica NVIDIA este disponibila.

Alternativ, se poate folosi Google colab.

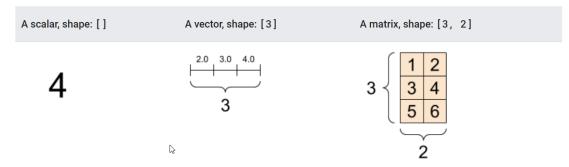
https://download.pytorch.org/whl/cu118

Tensori in PyTorch

Un tensor este un tablou de date multimensional. Orice tensor are un numar de dimensiuni. Astfel,

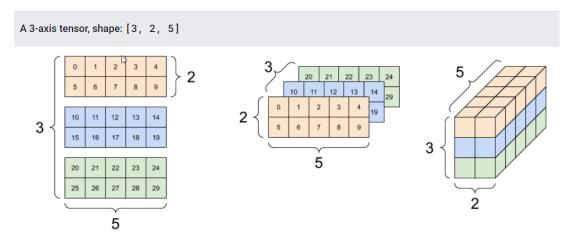
- un numar este un tensor de dimensiune 0
- un vector este un tensor de dimensiune 1

• o matrice e tensor de dimensiune 2



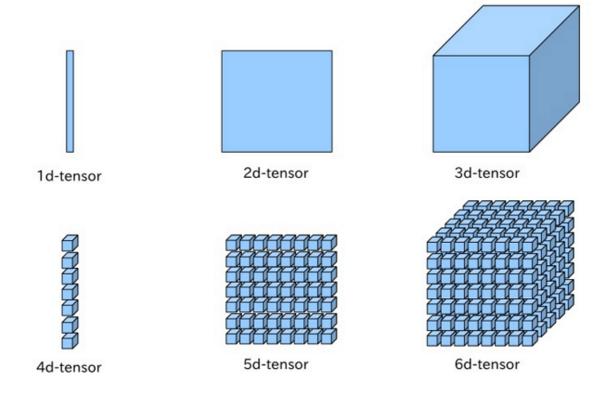
Sursa

avem tensori de dimensiuni 3: matrice stivuite



Sursa

• Tensori cu mai mult de 3 dimensiuni



Sursa

Modul de utilizare este destul de similar cu cel de la NumPy.

```
In [2]: import torch
print(f'Versiune torch: {torch.__version__}')

Versiune torch: 2.0.0+cu118

Putem vedea daca suportul de CLIDA este disponibil Daca da inseamna ca se pot face operatii
```

Putem vedea daca suportul de CUDA este disponibil. Daca da, inseamna ca se pot face operatii (calcule, antrenari de retele neurale) folosind placa grafica.

```
In [3]: torch.cuda.is_available()
Out[3]: True
```

Scalari ca tensori

```
scalar = torch.tensor(5)
In [4]:
         type(scalar)
        torch.Tensor
Out[4]:
In [5]:
        # valoarea variabilei
         scalar
         # observamm ca rezvultatul este obiect "tensor", ca la tipul de mai sus
        tensor(5)
Out[5]:
        # daca se stie ca tensorul are o valoare, atunci aceasta se acceseaza cu metoda item()
In [6]:
         scalar.item()
Out[6]:
In [7]:
        # numarul de dimensiuni al unui tensor scalar
         scalar.ndim
Out[7]:
```

Vector ca tensor

```
In [8]: vector = torch.tensor([1, 20, -3, 4.5, -3])
vector

Out[8]: tensor([ 1.0000, 20.0000, -3.0000, 4.5000, -3.0000])

In [9]: # avem tot tipul tensor pentru aceasta variabila type(vector)

Out[9]: torch.Tensor

In [10]: # numarul de dimensiuni este 1 vector.ndim
```

```
Out[10]:
          # un concept important pentru un tensor este "forma" sa: numarul de elemente pe fiecar
In [11]:
          vector.shape
          torch.Size([5])
Out[11]:
In [12]:
          # indicii functioneaza ca la vectorii NumPy; componentele individuale sunt tensori
          vector[1]
          tensor(20.)
Out[12]:
          # slicing pe tensori 1d functioneaza cu aceleasi conventii ca la NumPy
In [13]:
          vector[2:4]
          tensor([-3.0000, 4.5000])
Out[13]:
In [14]:
          # operatii pe tensori
          print('Suma dintre un vector si o constanta', vector + 100)
          Suma dintre un vector si o constanta tensor([101.0000, 120.0000, 97.0000, 104.5000,
          97.0000])
          # inmultirea unui tensor cu o constanta
In [15]:
          vector*(-2)
          tensor([ -2., -40., 6., -9.,
                                             6.])
Out[15]:
          # suma a doi tensori
In [16]:
          vector + 2 * vector
          tensor([ 3.0000, 60.0000, -9.0000, 13.5000, -9.0000])
Out[16]:
In [17]:
          # produsul scalar al doi tensori
          torch.dot(vector, vector)
          tensor(439.2500)
Out[17]:
          # norma unui tensor
In [18]:
          torch.norm(vector)
          tensor(20.9583)
Out[18]:
          # pe tensor: minim, media, prima pozitie a minimului
In [19]:
          torch.min(vector), vector.max(), torch.argmin(vector)
          (tensor(-3.), tensor(20.), tensor(2))
Out[19]:
          Dupa cum se observa, operatiile cunoscute din NumPy se regasesc si aici. Diferenta principala
          este ca rezultatul unei operatii este de regula un tensor.
```

Conversia de la tensor la tablou NumPy se face cu:

```
In [20]: numpy_vector = vector.numpy()
print(f'tip: {type(numpy_vector)}')
```

```
print(f'valoare: {numpy_vector}')

tip: <class 'numpy.ndarray'>
valoare: [ 1. 20. -3. 4.5 -3. ]
```

Un tensor este prelucrabil de catre un anumit dispozitiv (CPU, GPU, TPU etc.). Implicit acest dispozitiv este CPU:

```
In [21]: vector.device
Out[21]: device(type='cpu')
```

Trecerea unui tensor pe alt dispozitiv se face in mod explicit. De exemplu, pentru a trece vector pe GPU (presupunand ca este prezenta o placa grafica pe sistem si ca instalarea de Pytorch s-a facut cu versiune de GPU) operam astfel:

```
In [22]: # instructiunea de mai jos va da eroare daca nu este disponibil cuda
    vector = vector.cuda()
    vector.device
    # ar trebui sa se afiseze: device(type='cuda', index=0)
    # index=0 se refera la a cata placa video este folosita pentru procesarea tensorului
```

Out[22]: device(type='cuda', index=0)

Operatiile se pot face doar cu tensori procesati de acelasi dispozitiv.

```
In [23]: vector2 = torch.from_numpy(numpy_vector)
vector.device, vector2.device

Out[23]: (device(type='cuda', index=0), device(type='cpu'))
```

```
In [24]: # executia liniei de mai jos produce eroare:
# s = vector + vector2
# RuntimeError: Expected all tensors to be on the same device, but found at least two
```

"Trecerea" unui tensor de pe CUDA pe CPU se face cu:

```
In [25]: vector = vector.cpu()
   vector.device

Out[25]: device(type='cpu')
```

Matrice ca tensori

Tensori cu mai mult de 2 dimensiuni

```
In [31]: tensor3d = torch.tensor([[
             [20, -6, 3, 5],
             [13,44,121, 199],
             [-11, -19, -20, -21]],
             [[11, -99, 67, 40],
             [22,23,24,25],
             [-100, -101, -102, -103]]]
         )
         print(f'numar de dimensiuni: {tensor3d.ndim}')
In [30]:
         print(f'forma: {tensor3d.shape}')
         numar de dimensiuni: 3
         forma: torch.Size([2, 3, 4])
         # prima matrice este cu index 0:
In [31]:
         print(tensor3d[0, ...])
         tensor([[ 20, -6, 3, 5],
                 [ 13, 44, 121, 199],
                 [-11, -19, -20, -21]
         # mecanismul de broadcasting functioneaza dupa aceleasi principii ca in NumPy
In [32]:
         tensor2d = torch.arange(10, 22).reshape(3, 4)
         tensor3d + tensor2d
         tensor([[[ 30,
                          5, 15, 18],
Out[32]:
                  [ 27, 59, 137, 216],
                  [ 7, 0, 0,
                                  0]],
                 [[ 21, -88, 79, 53],
                  [ 36, 38, 40, 42],
                  [-82, -82, -82, -82]]])
In [33]: # tensor 4d
         tensor4d = torch.rand(3, 4, 2, 7)
         print(f'numarul de dimensiuni ale lui tensor4d: {tensor4d.ndim}')
         print(f'forma lui tensor4d: {tensor4d.shape}')
         numarul de dimensiuni ale lui tensor4d: 4
         forma lui tensor4d: torch.Size([3, 4, 2, 7])
         # tensor plin cu 0
In [34]:
         tensor0 = torch.zeros(3, 4)
         tensor0_4d = torch.zeros_like(tensor4d)
```

Transformare de imagine in tensor

O imagine color este un tensor tridimensional. Dupa citire, se poate transforma intr-un tensor Pytorch.

```
In [35]: # daca e necesar, pentru PIL
#!pip install pillow
from PIL import Image
import numpy as np
image = Image.open('./images/beach.jpg')
display(image)
```



Se poate obtine un tablou NumPy din imagine:

```
image_numpy = np.array(image)
print(image_numpy.shape)

(480, 640, 3)
```

Valorile minime si maxime din imagine sunt:

```
In [37]: np.min(image_numpy), np.max(image_numpy)
Out[37]:
```

Dorim sa transformam imaginea intr-un tensor Pytorch. In plus, deoarece valorile mari ale pixelilor (0..255) nu sunt potrivite pentru calculele de inmultire si adunare cu ponderi, se prefera scalarea lor la intervalul \$[0, 1]\$ sau standardizarea lor (valoarile pe fiecare canal să fie cu medie si deviatie standard 1).

Mai jos se face simultan conversia la tensor si scalare. Se observa si schimbarea formei tabloului: in numpy are forma (480, 640, 3), in Pytorch capata forma (3, 480, 640) - numarul de canale da prima dimensiune.

```
import torchvision.transforms as transforms
In [38]:
          transform = transforms.ToTensor()
          image tensor = transform(image)
          print(image_tensor.shape)
         torch.Size([3, 480, 640])
         print(image_tensor)
In [39]:
         tensor([[[0.4745, 0.4745, 0.4745, ..., 0.7608, 0.7608, 0.7608],
                   [0.4784, 0.4784, 0.4784,
                                             ..., 0.7647, 0.7647, 0.7647],
                   [0.4824, 0.4824, 0.4824,
                                             ..., 0.7647, 0.7647, 0.7647],
                   [0.2863, 0.2706, 0.2118,
                                             ..., 0.8314, 0.6392, 0.8667],
                                             ..., 0.7490, 0.6039, 0.8078],
                   [0.2549, 0.2706, 0.3882,
                   [0.2824, 0.3922, 0.3843,
                                             \dots, 0.7137, 0.5686, 0.7804]],
                  [[0.7020, 0.7020, 0.7020,
                                             ..., 0.8863, 0.8863, 0.8863],
                   [0.7059, 0.7059, 0.7059,
                                             ..., 0.8902, 0.8902, 0.8902],
                   [0.7098, 0.7098, 0.7098,
                                             ..., 0.8902, 0.8902, 0.8902],
                   [0.3529, 0.3333, 0.2627,
                                            ..., 0.9333, 0.7137, 0.8902],
                   [0.3216, 0.3333, 0.4353, ..., 0.8784, 0.6863, 0.8510],
                   [0.3490, 0.4549, 0.4314,
                                             ..., 0.8667, 0.6784, 0.8353]],
                  [[0.8902, 0.8902, 0.8902, ..., 0.9686, 0.9686, 0.9686],
                   [0.8941, 0.8941, 0.8941,
                                             ..., 0.9725, 0.9725, 0.9725],
                   [0.8902, 0.8902, 0.8902,
                                             ..., 0.9725, 0.9725, 0.9725],
                   [0.0745, 0.0784, 0.0549, \ldots, 0.9294, 0.6902, 0.8431],
                   [0.0431, 0.0863, 0.2392, ..., 0.9059, 0.6980, 0.8353],
                   [0.0706, 0.2078, 0.2353, \ldots, 0.9333, 0.7333, 0.8784]]])
         # valoarea minima si maxima din tensor:
In [40]:
          image_tensor.min(), image_tensor.max()
         (tensor(0.), tensor(1.))
Out[40]:
         Redimensionarea imaginii se poate face tot printr-o transformare:
         resize = transforms.Resize([224, 224], antialias=False)
In [41]:
         image resized = resize(image tensor)
In [42]:
          print(image resized.shape)
         torch.Size([3, 224, 224])
```

Cele doua transformari pot fi compuse intr-o secventa:

```
In [43]:
         transform = transforms.Compose([transforms.ToTensor(), transforms.Resize([224, 224], a
          image tensor scaled resized = transform(image)
          print(image tensor scaled resized.shape)
          assert torch.equal(image tensor scaled resized, image resized)
         torch.Size([3, 224, 224])
         Pentru standardizarea imaginii trebuie sa stim media si dispersia pe fiecare canal.
         image = Image.open('./images/beach.jpg')
In [44]:
          transform = transforms.ToTensor()
          # transformare in tensor, scalare in [0,1]
          image tensor = transform(image)
          mean, std = image tensor.mean([1,2]), image tensor.std([1,2])
          print("mean and std before scaling:")
          print("Mean of the image:", mean)
          print("Std of the image:", std)
          # pentru ultima linie afisata: sunt deviatiile standard pentru canalele rosu, verde, r
         mean and std before scaling:
         Mean of the image: tensor([0.3916, 0.5372, 0.6126])
         Std of the image: tensor([0.2389, 0.2117, 0.3052])
         transform_scale = transforms.Compose([
In [45]:
              transforms.ToTensor(),
              transforms.Normalize(mean, std) # scalarea este numita normalizare in Pytorch
          1)
          image_scaled = transform_scale(image)
          mean scaled, std scaled = image scaled.mean([1,2]), image scaled.std([1,2])
          print("mean and std after scaling:")
          print("Mean of the image:", mean_scaled)
          print("Std of the image:", std_scaled)
         mean and std after scaling:
         Mean of the image: tensor([-9.4871e-09, -1.7573e-07, -1.5895e-09])
         Std of the image: tensor([1., 1., 1.])
```